



# 力情報を扱うVLAモデルについて

株式会社ACCESS IoT開発本部 先端技術開発室 鎌田大己

2026.02.13



# 目次

## 1. 導入

- VLA / VTLA モデルとは？
- なぜ力情報が必要か？
- 力情報をどのように活用できるか？
- 研究一覧

## 2. センシング — 力情報の取得方法

## 3. アーキテクチャ

- $\pi_0$  モデルのアーキテクチャ
- 力情報の注入方法

## 4. 制御方式 — 制御方式と出力拡張

## 5. 課題・まとめ

## 6. 参考文献

## 7. Appendix

# 01

## 導入

# VLA / VTLA モデルとは？



Figure 1: VLA モデル（左）と VTLA モデル（右）の比較。赤が力情報の拡張部分。

**VLA モデル:** 視覚・言語・関節状態を入力し、関節位置を出力するマルチモーダル模倣学習モデル

**VTLA モデル:** VLA の入力やアクションにトルク・触覚画像などの **力情報 (Tactile)** を追加したもの

※ ACT のような VA モデル（言語なし）の拡張も含めて本スライドでは VTLA と総称する

**本スライドの対象:** 模倣学習（デモデータからの追加学習）前提の VTLA モデルに関する最近の研究をサーベイし、力のセンシング・VLA モデルの力拡張方法・制御方式の観点から整理する。

# なぜ力情報が必要か？

従来の VLA モデルの模倣学習・fine-tune は視覚・位置情報のみに依存しており、以下の課題を抱えている:

## データ収集時

- ・ 位置制御テレオペ（遠隔操作）では力のフィードバックがなく、触覚に依存しないポリシーになりがち [1]
- ・ テレオペは非効率（ズッキーニ皮剥きでは FB ありの場合は 5 分 に対して 13 分） [2]

## 観測データ（入力）

- ・ 接触リッチなタスクの成功率が極めて低い — 充電器挿入 **0%** [3]、柔らかい物体(食品等)の把持 **13%** [1]、5 タスク平均 **37%** [4]
- ・ 視覚だけでは物体の物理特性がわからない — 硬さ・力の判別はランダム推測と同等（各 **50%**） [5]
- ・ 視覚が劣化すると操作不能 — 暗環境でタスク失敗 [6] / 視覚遮蔽下のプラグ挿入 **60%** [4]

## アクション（出力）

- ・ 力加減ができず物体を破損 — 位置制御のみの皮むきで **20N**（一部 40N 超）を印加 [2]
- ・ 副詞（softly, hard）で力加減を言語指示しても加減不能 [1]

# 力情報をどのように活用できるか？

## データ収集時

- ・バイラテラル制御（力の双方向伝達）でリーダーの操作者がフォロワーの触覚を感じながら動作を収集できる

## 観測データ（入力）

- ・把持の精度・滑らかさが向上 — 触覚入力で把持成功率が向上（75.0%→**96.9%**）、完了時間も **24%** 削減 [7]
- ・タスク成否・物体特性を判断 — トルク変化で接触失敗を検知し自律リトライ（ボタン押し 5→**10/20**）[3] / 触覚で硬さ・力を判別（硬さ **75%**・力 **90%**）[5]
- ・視覚に依存しない操作 — 遮蔽下のプラグ挿入（60%→**90%**）[4] / 暗環境でもペグ挿入に成功（VLA は失敗）[6]

## アクション（出力）

- ・過大な力を抑制 — 皮むき時の接触力を抑制（20N→**9N**）、成功率向上（55%→**85%**）[2]
- ・力の時間的変化パターンの理解 — 将来トルクを補助タスクとして(=制御には不使用) 予測し、力応答の因果関係を学習 [3]

## 言語指示

- ・副詞に応じた力の出し分けを学習（「softly」→**0.5N** / 「hard」→**2.57N**）。未学習の副詞の汎化も達成（「harder」→**2.94N**）[1]

- ・**データ収集時**: 力情報のフィードバックにより高品質・効率的なデモ収集が可能
- ・**観測データ**: 視覚だけではわからない物体特性の情報が得られる
- ・**アクション**: トルクを出力することで、過大な力を抑制するなどの力加減が可能になる
- ・**(言語指示)**: 力加減を自然言語で指示できる

# 研究一覧

| 研究          | カメラ   | カセンシング          | ベース         | 力の入力方法                        | 出力         | 制御         |
|-------------|-------|-----------------|-------------|-------------------------------|------------|------------|
| ForceVLA    | RGB×2 | ③ 内蔵推定値(6 軸)    | $\pi_0$ [8] | ②-a AE 側 (MoE)                | 位置         | ① 位置制御     |
| OmniVTLA    | RGB×2 | ②+③ 触覚画像+トルクセンサ | $\pi_0$     | ① VLM 側 (Enc 有)               | 位置         | ① 位置制御     |
| Tactile-VLA | RGB   | ③ トルクセンサ        | $\pi_0$     | ① VLM 側 (Enc 有)               | 位置+目標力     | ②-a 力補正付き  |
| TA-VLA      | RGB×3 | ① 関節トルク         | $\pi_0$     | ②-b AE 側 (MLP)                | 位置+将来トルク   | ① 位置制御     |
| VTLA        | RGB×1 | ② 触覚画像          | Qwen2-VL    | ① VLM 側 (Enc 有)               | 位置         | ① 位置制御     |
| ForceMimic  | 点群    | ③ トルクセンサ        | 拡散ポリシー      | —                             | 位置+6 軸力    | ②-b ハイブリッド |
| VLA-Touch   | RGB×2 | ② 触覚画像          | RDT-1B      | ① VLM 側 (Enc 無 <sup>†</sup> ) | 位置         | ① 位置制御     |
| Bi-ACT/LAT  | RGB×2 | ① 関節トルク         | ACT         | ②-c 直接結合                      | 角度+角速度+トルク | ②-b ハイブリッド |

## 分類の概要:

### カセンシング (2 章)

- ・ ① 関節トルク (内部推定)
- ・ ② 触覚画像 (外部・2D 画像取得)
- ・ ③ トルクセンサ (外部・値取得)

### 力の付加方法 (3 章)

- ・ ① VLM 側 (Enc 有/無)
- ・ ②-a AE 側 (MoE: 混合エキスパート)
- ・ ②-b AE 側 (MLP: 多層パーセプトロン)
- ・ ②-c 直接結合

### 制御方法 (4 章)

- ・ ① 位置出力→位置制御
- ・ ②-a 位置+力出力→力補正付き
- ・ ②-b 位置+力出力→ハイブリッド

# 02

## センシング



# 力情報の取得方法

## ① 関節トルク (モーターからトルクを直接取得 or 推定)

- ・ モーター電流や外乱オブザーバからトルクを推定。追加 HW 不要
- ・ ○ 低コスト・外部センサ不要で導入が容易
- ・ △ ノイズ・熱ドリフトの影響 / 接触位置は得られない
- ・ 採用: TA-VLA [3] ( $\tau = k_t \cdot i$ ;  $k_t$ : トルク定数,  $i$ : 電流)、Bi-ACT/LAT [9] (外乱オブザーバにより実トルク推定)

## ② 触覚画像 (外部の接触センサから 2D 画像化)

- ・ 接触面の变形を画像データとして取得 (GelSight 等)
- ・ ○ 高空間解像度で接触状態を詳細に把握
- ・ △ 低時間解像度 (20–30 Hz) / コスト・摩耗・形状制約
- ・ 採用: OmniVTLA [7] (GelSight)、VTLA [6] (GelStereox2)、VLA-Touch [5] (GelSight Mini)

## ③ トルクセンサ (外部センサから値を取得)

- ・ 力・トルクの数値をセンサで直接取得
- ・ ○ 高時間解像度 (~1 kHz)・6DoF (6 自由度)
- ・ △ 専用センサが必要 / 高コスト / 推定値は精度に限界
- ・ 採用: ForceVLA [4] (Flexiv (ロボットアーム) の内蔵推定値)、ForceMimic [2] (外付 6 軸実測)、Tactile-VLA [1] (法線+せん断力)、OmniVTLA [7] (Paxini (力覚触覚センサ))



Figure 2: GelSight Mini




Figure 3: 触覚センサの装着例  
(Tactile-VLA [1] Fig.4)

Tactile Image Sequence (Left Finger)




Figure 4: GelStereo の触覚画像

# 03

## アーキテクチャ

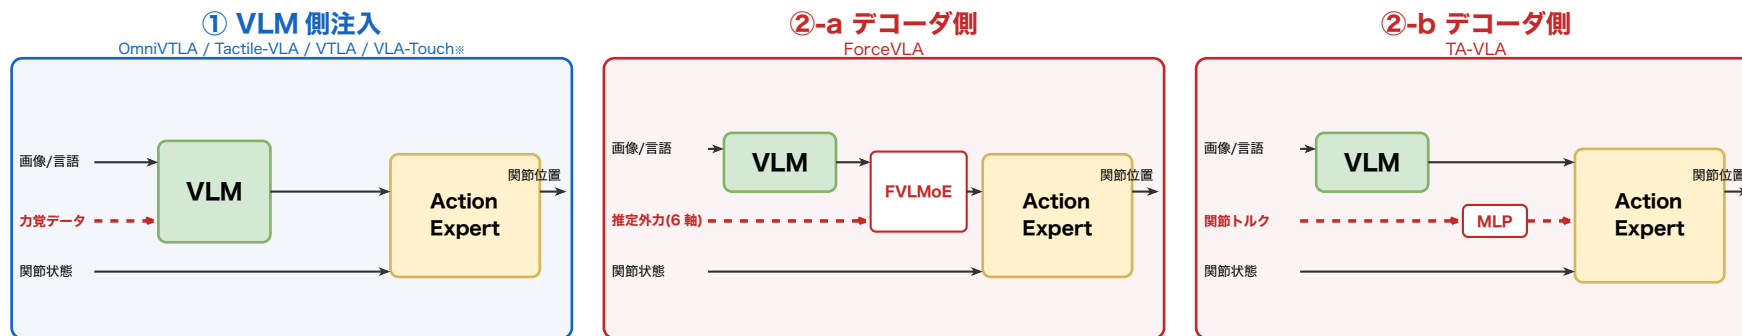
# $\pi_0$ モデル [8] のアーキテクチャ

サーベイ対象の多くは  $\pi_0$  や ACT (Appendix 参照) 等の既存モデルを拡張し、力情報の入出力を追加している。以下ではベースとなる  $\pi_0$  の構造を示す。



- ・ **エンコーダ** (SigLiP): RGB 画像 → トークン列に変換
- ・ **VLM** (PaliGemma 3B): 画像トークン+言語指示を統合し「何をすべきか」を理解
- ・ **Action Expert** (300M param, Flow Matching): VLM 出力を条件に  $H=50$  ステップのアクションチャंक（行動予測列）を生成

# 力情報の注入方法



- ① **VLM 側**: 力覚データ（触覚画像やセンサ値）をトークン化し VLM へ入力（OmniVTLA [7] / Tactile-VLA [1] / VTLA [6]）※VLA-Touch [5] は触覚を言語化（VLA 未改変）
- ② **デコーダ側**: Action Expert 周辺で力を融合 — 両研究とも複数手法を比較し以下が最良
  - ②-a **ForceVLA** [4]: **FVLMoE** — VLM 出力トークンと推定外力(6 軸)を 4 エキスパート MLP で選択的に融合
  - ②-b **TA-VLA** [3]: **DePost** — 関節トルク履歴を MLP で 1 トークンに集約し AE の状態入力  $q_t$  の前に追加
    - $\pi_0$  の AE 入力は  $[q_t]$  の 1 トークン。DePost は  $[\text{MLP}(\tau_{t-H:t}), q_t]$  の 2 トークンになるが、 $q_t$  自体は変えないので事前学習パターンの崩れが小さい
  - ②-c **TA-VLA** [3]: **DePre** —  $q_t$  のゼロパディング次元にトルクを埋め込み 1 トークンのまま入力
    - $q_t$  の中身自体が変わるため②-b より性能低下


性能順: **TA-VLA** [3]: ②-b > ②-c > ①    **ForceVLA** [4]: ②-a(FVLMoE) 80% > ②-a'(VLM 出力と力の concat  $[E_{VL}; \varphi(f)]$ ) 60% > ① 55% >  $\pi_0$  45%

①でも改善はあるが、②のようにデコーダ側で MoE/MLP 等により力情報を融合させる程、性能が高くなる傾向がある

# 04

## 制御方式

# 制御方式と出力拡張



- ① 位置出力 → 位置制御（多数派）：力情報は入力のみで活用、出力は目標姿勢のみ（ForceVLA [4] / OmniVTLA [7] / VTLA [6] / VLA-Touch [5]）
  - TA-VLA [3]: 位置に加え将来トルク  $\tau$  も同時に予測させることで、力応答の因果関係を学習（出力拡張あり、制御自体は位置のみ。Appendix 参照）
- ② 位置+力出力（Appendix 参照）：関節位置に加え目標力・将来トルクも同時予測
  - ②-a Tactile-VLA [1]（力補正付き）： $F_{\text{target}}$  を予測し力誤差  $\Delta F$  が閾値超過時のみ位置補正
  - ②-b ハイブリッド（位置と力を軸ごとに切替）：接触力を直接制御
    - ForceMimic [2]: 位置+6 軸力を出力。予測力  $< 6\text{N}$  → 位置制御 /  $\geq 6\text{N}$  → ハイブリッド
    - Bi-ACT/LAT [9]: 角度+角速度+トルクを出力しバイラテラル制御（位置追従+作用反作用）で駆動

出力に力を加えることで「力を知る」だけでなく「力を制御する」ことが可能に

# 05

## 課題・まとめ

# 課題・まとめ

## サーベイの要旨:

- ・ VLA モデルに力情報を統合する VTLA 研究を、**センシング・アーキテクチャ・制御方式**の 3 軸で整理した

## 各軸の傾向:

- ・ **センシング:** 関節トルク・触覚画像・トルクセンサの 3 種があり、コスト・解像度・導入容易性のトレードオフがある。複数を組み合わせた研究もみられる
- ・ **アーキテクチャ:** 力情報の注入先として VLM 側とデコーダ側の 2 方式がある。デコーダ側の方が事前学習済み VLM の表現を保持しやすく、性能面でも優位な傾向が報告されている
- ・ **制御方式:** 多くの研究は位置制御のみだが、力補正やハイブリッド制御を導入した研究では、接触を伴うタスクでの改善が示唆されている

## 残された課題:

- ・ **データ収集:** テレオペでの力フィードバック欠如により触覚に依存しない動作になりがち [1], [2]。インターネット動画に力データが存在しない点もスケーラビリティを制約する [2]
- ・ **学習:** カトークンの追加が VLM やデコーダの事前学習パターンを崩す場合がある [3], [4]。注入位置・トークン数の設計が性能に直結する
- ・ **推論:** カセンサの高サンプリングレート (100Hz-1kHz) に対しモデル推論が低速 (8-20Hz) で、高周波情報を活用しきれていない [1], [5]。モータ電流ベースのトルク推定では熱ドリフトによる長時間精度低下も指摘されている [3]
- ・ **評価:** 各研究が独自のタスク・HW・ベースラインで評価しており、横断的な比較が困難な状況にある



# 参考文献

- [1] H. Wang, X. Li, Y. Zhang, J. Chen, and H. Liu, "Tactile-VLA: Tactile Visual-Language-Action Model."
- [2] T. Chen, M. Zhang, and K. Liu, "ForceMimic: Force-Aware Imitation Learning."
- [3] X. Li, Z. Zhang, X. Chen, Y. Zhao, and W. Liu, "TA-VLA: Torque-Augmented Visual-Language-Action Model."
- [4] X. Wang et al., "ForceVLA: Unlocking Force-Aware Robotic Learning via Multi-Modal Visual-Language-Action Model."
- [5] D. Patel, W. Shen, J. Huang, and X. Chen, "VLA-Touch: Tactile-Visual-Language-Action Model with Touch Sensing."
- [6] Y. Zhang, M. Li, C. Wang, and H. Liu, "VTLA: Vision-Tactile-Language-Action Model."
- [7] Z. Zhang, X. Chen, W. Li, Y. Zhao, W. Liu, and Y. Li, "OmniVTLA: Omni-Embodiment Vision-Touch-Language-Action."
- [8] K. Black et al., " $\pi_0$ : A Vision-Language-Action Flow Model for General Robot Control".
- [9] C.-m. Kim, J. Lee, Y.-j. Kim, J.-h. Choi, H.-s. Kim, and D.-w. Park, "Bi-ACT: Bilateral Teleoperation-Augmented Action Chunking with Transformers."
- [10] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, "Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware."
- [11] C.-m. Kim, J. Lee, Y.-j. Kim, J.-h. Choi, H.-s. Kim, and D.-w. Park, "Bi-LAT: Bilateral Telemanipulation with Language-Augmented Transformers."
- [12] X. Liu, Z. Zhang, and others, "RDT-1B: a Diffusion Foundation Model for Bimanual Manipulation."
- [13] C. Chi et al., "Diffusion Policy: Visuomotor Policy Learning via Action Diffusion."
- [14] P. Wang and others, "Qwen2-VL: Enhancing Vision-Language Model's Perception of the World at Any Resolution."
- [15] M. J. Kim and others, "OpenVLA: An Open-Source Vision-Language-Action Model."
- [16] A. Brohan and others, "RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control."
- [17] Octo Model Team, "Octo: An Open-Source Generalist Robot Policy."

# A

## Appendix

# Appendix: 力情報の融合方式比較（成功率）

**ForceVLA [4]** プラグ挿入タスク（精密なアライメント+力制御）

| 融合方式                                          | 成功率 |
|-----------------------------------------------|-----|
| ベースライン ( $\pi_0$ )                            | 45% |
| ① VLM 前に linear — 力を線形射影し VLM 入力に追加           | 55% |
| VLM 後に concat — カトークンを VLM 出力に連結し AE 入力へ      | 60% |
| ②-a FVLMoE — 4 エキスパート MLP + Top-1 ルーティングで動的融合 | 80% |

**TA-VLA [3]** ボタン押し＝接触検知+押下、充電器挿入＝精密アライメント+力制御


| 融合方式               | ボタン押し | 充電器挿入 |
|--------------------|-------|-------|
| $\pi_0$ （ベースライン）   | 5/20  | 0/20  |
| ① Enc（エンコーダ側）      | 7/20  | 8/20  |
| DePre（デコーダ前段）      | 8/20  | 11/20 |
| ②-b DePost（デコーダ後段） | 10/20 | 12/20 |

# Appendix: HW 構成一覧

| 研究              | ロボット                            | カメラ                         | カセンシング                                                 |
|-----------------|---------------------------------|-----------------------------|--------------------------------------------------------|
| ForceVLA [4]    | Flexiv Rizon 7-DoF <sup>†</sup> | RealSense D435+D415         | ロボット内蔵推定値（6 軸）                                         |
| TA-VLA [3]      | Cobot Magic ALOHA（×2, 7DoF）     | RealSense D435×3            | 関節トルク（ $\tau = k_t \cdot i$ ； $k_t$ : トルク定数, $i$ : 電流） |
| OmniVTLA [7]    | UR5 + グリッパー / 多指ハンド（4 本指）       | リスト+ベース（型番不明）               | 触覚画像（GelSight）+ トルクセンサ（Paxini（力覚触覚センサ））                |
| VTLA [6]        | UR3（6-DoF）                      | RealSense D405（手首）          | 触覚画像（GelStereo 2.0×2, 20Hz）                            |
| Tactile-VLA [1] | UMI 拡張                          | RGB（20Hz）                   | トルクセンサ（法線+せん断力, 100→20Hz）                              |
| ForceMimic [2]  | Flexiv Rizon 4                  | RealSense L515 + T265（SLAM） | トルクセンサ（外付 6 軸実測, 1kHz）                                 |
| VLA-Touch [5]   | Franka Emika Panda              | RealSense ×2（シーン+手首）        | 触覚画像（GelSight Mini）                                    |
| Bi-ACT/LAT [9]  | OpenMANIPULATOR-X（4+1 DoF）      | RGB×2                       | 関節トルク（外乱オブザーバ, 1kHz）                                   |

<sup>†</sup>Quest 3 VR でテレオペ。Bi-ACT/LAT はバイラテラル制御（リーダー・フォロワー）でデータ収集。Tactile-VLA・Bi-ACT/LAT の RGB は元論文に具体型番の記載なし。

# Appendix: ACT モデル [10] のアーキテクチャ



- **エンコーダ** (ResNet18): RGB 画像 (ACT: 4 枚, Bi-ACT: 2 枚) を特徴マップに変換し、Decoder に渡す
- **CVAE** (学習時のみ): 人間のデモには「同じ状況でも異なる軌道を取る」ばらつきがあるため、それを潜在変数  $z$  で吸収する。推論時は  $z = 0$  に固定
- **Transformer Decoder**: 画像特徴・関節状態・潜在変数  $z$  から、次の  $k$  ステップ分の関節位置をまとめて予測する (アクションチャンク)。重複するチャンクは指数加重平均で結合し、動きをなめらかにする ※sim 実験では  $k=100$
- **Bi-ACT/LAT 拡張 [9], [11]**: 関節トルク (外乱オブザーバで推定) を状態に追加するとともに、エンコーダ (SigLIP) で言語条件付けを行い、バイラテラル制御で力情報付きデータを収集する

## Appendix: ② 位置+力出力 — 3 研究の制御詳細

### ②-a Tactile-VLA [1] (力補正付き位置制御)

- VLA が位置に加え目標力  $F_{\text{target}}$  を出力する。力誤差  $\underbrace{\Delta F}_{\text{目標と実測の差}} = F_{\text{tgt}} - F_{\text{meas}}$  が閾値  $\tau_{\text{th}}$  を超えたときのみ位置を補正する (

$$\underbrace{P_{\text{hyb}}}_{\text{補正後の位置}} = \underbrace{P_{\text{tgt}}}_{\text{目標位置}} + K \underbrace{\Delta F}_{\text{力誤差}}$$

)

- 外力はグリッパ位置で補正し、把持力はグリッパ幅で独立に調整する。「softly」→ 0.5N のように言語と力の対応も学習できる

### ②-b ForceMimic [2] (適応ハイブリッド制御)

- 位置と 6 軸力を同時に出力する。予測力が小さいとき ( $\hat{F} < 6\text{N}$ ) は位置制御のみ、大きくなると軸ごとに位置と力を分けて制御する
- 1kHz の F/T (力/トルク) センサを用いるため高精度な力制御が可能。皮むき時の接触力を 20N → 9N に抑制し成功率が向上 (55%→85%)

### ②-b Bi-ACT/LAT [9] (バイラテラル制御)

- 角度・角速度・トルクを出力し、リーダー・フォロワー構成で位置追従と作用反作用を同時に実現する
- データ収集時にバイラテラル制御を使うことで、力情報付きのデモを自然に収集できる。外乱オブザーバを用いて 1kHz でトルクを推定している

# Appendix: TA-VLA — トルク履歴の入力方法と将来トルク予測

## ① トルク履歴をどう入力するか:

トルクは接触の瞬間に急変するため、1 フレームだけでは変化の傾向がわからない → 過去数フレーム分の履歴を使いたい

| 入力方法                  | 結果   |
|-----------------------|------|
| 各フレームを別々のトークンとして入力    | 性能低下 |
| 履歴全体を MLP で 1 トークンに集約 | 最良   |

なぜ? トークン数が増えると、 $\pi_0$  が事前学習で覚えた入力パターンが崩れてしまう。情報が多少失われても 1 トークンにまとめた方がよい

RDT ベースでも有効 — ベースモデルに依存しない汎用的手法 (各 20 試行) :

| タスク   | RDT (ベースライン) | RDT + トルク入力 + トルク予測 | $\Delta$ |
|-------|--------------|---------------------|----------|
| ボタン押し | 4/20         | 16/20               | +12      |
| 充電器挿入 | 1/20         | 15/20               | +14      |
| ボトル移動 | 17/20        | 19/20               | +2       |

## ② 将来トルクも同時に予測させる:

位置だけでなく「次に発生するトルク」も一緒に予測させることで、モデルが力の因果関係を学習する

損失関数:

$$\mathcal{L}_{\text{joint}}(\theta) = \underbrace{\mathcal{L}_{\text{action}}(\theta)}_{\text{位置予測の誤差}} + \beta \cdot \underbrace{\mathcal{L}_{\text{torque}}(\theta)}_{\text{トルク予測の誤差}}$$

ポイント: 推論時にトルク予測は使わない (制御は位置のみ)。あくまで学習を助ける補助的な役割

## Appendix: 各研究の評価タスク一覧

| 研究              | 主な評価タスク                                                        |
|-----------------|----------------------------------------------------------------|
| ForceVLA [4]    | ボトルポンピング / プラグ挿入 / USB 挿入 / ボード拭き / きゅうり皮むき（+汎化: 物体・高さ・視覚遮蔽）   |
| Bi-ACT/LAT [9]  | ピック & プレース（多様形状・重量） / 引き出し収納                                   |
| OmniVTLA [7]    | ピック & プレース（グリッパー: 缶・ボトル等 / 多指ハンド: ボトル・牛乳パック）                   |
| TA-VLA [3]      | ボタン押し / 充電器挿入 / ボトル移動 / 液体注ぎ / 積み重ね / 押し込み / 引き出し開け / ドアハンドル回転 |
| Tactile-VLA [1] | USB・充電器挿抜 / 卓上物体把持（12 種） / ボード拭き（+未学習の黒板拭き）                    |
| VTLA [6]        | ペグイン穴挿入（5 形状 × 0.6–2.0mm クリアランス、Sim2Real）                      |
| ForceMimic [2]  | ズッキーニ皮むき                                                       |
| VLA-Touch [5]   | カップ操作（水の有無判定+配置） / 拭き取り（スポンジ選択+拭き） / 皮むき（熟度判定+皮むき）             |

**傾向:** 挿入・把持・皮むき等の**接触リッチ**なタスクが中心。各研究が独自タスクで評価しており横断的比較が困難 — 標準ベンチマークの整備が課題。